

Dokumen

05_Source_Code — Replikasi Deteksi Hoaks (Naïve Bayes + TF-IDF)

Penyusun: Abiansyah

Replikasi paper Pratiwi, Asmara & Rahutomo (2017), “Study of hoax news detection using naive bayes classifier in Indonesian language” (ICTS 2017, DOI 10.1109/ICTS.2017.8265649), dengan dataset Mendeley CC BY 4.0 (DOI 10.17632/p3hfgr5j3m.1).

Yang direplikasi

- **Metode usulan:** TF-IDF + Multinomial Naive Bayes, tuning alpha, diuji pada 3 skema split (60-40, 70-30, 80-20) seperti paper.
- **Baseline pembeding:** TF-IDF + Linear SVM, TF-IDF + Logistic Regression.
- **Metrik:** Accuracy, Precision, Recall, F1 + confusion matrix.

Struktur

Script/
config.py # pusat seed, path, skema split, parameter
preprocessing.py # load Mendeley CSV -> bersihkan teks ID -> clean.csv
train_eval.py # latih usulan + baseline, evaluasi, simpan hasil
Notebook/
(opsional, bisa dibuat memanggil script di atas)

Library

pip install pandas numpy scikit-learn matplotlib
opsional (stemming/stopword lebih baik): pip install Sastrawi

Cara jalan (urut)

1. Unduh dataset sesuai 04_Dataset/Dataset_Source.txt, taruh CSV di Raw_Dataset/.
2. cd Script && python preprocessing.py → menghasilkan clean.csv.
3. python train_eval.py → hasil di 07_Hasil_Eksperimen/, confusion di 08_Visualisasi/, model di 06_Model/.

Catatan kejujuran (penting untuk laporan)

1. **Hasil tidak akan identik dengan paper.** Paper 2017 tidak merinci semua parameter preprocessing & TF-IDF. Skrip ini memakai pilihan wajar (stopword ringkas, max_features=5000, unigram) + seed tetap. Angka Anda akan *mendekati*, bukan sama persis — wajar dalam replikasi, dan bisa jadi bahan diskusi.
2. **Stopword/stemming disederhanakan** (tanpa dependensi). Untuk lebih dekat ke standar NLP Indonesia, ganti dengan Sastrawi (stemming + stopwords resmi). Ini bisa Anda sebut sebagai potensi pengembangan.
3. **Baseline (SVM, LogReg) adalah tambahan** untuk memenuhi syarat metode pembeding tugas

— paper aslinya fokus Naive Bayes.

4. **Verifikasi status SINTA paper acuan** sebelum submit (ICTS 2017 = conference IEEE; bila dosen wajib *jurnal* SINTA, pasangkan dengan paper jurnal SINTA yang juga memakai dataset Mendeley ini).